

Міністерство освіти і науки України
Львівський національний університет
Факультет електроніки та комп'ютерних технологій

Звіт

До індивідуального завдання з теми:

«Бінування даних лінгвістичної статистики»

Виконав:
Студент ФЕІм-14
Варіводін М.Д.
Перевірив:
Кушнір О.С.

Львів 2025

Зміст

Зміст.....	2
Хід роботи(інструкція).....	4
Відкрити папку з текстами	4
Порахувати слова в текстах.....	4
Порахувати символи в текстах.....	6
Ігнорувати регістр	6
З пропусками	7
Відкрити словник	7
Відкрити файл бінування.....	8
Зберегти словник у декількох форматах	9
Зберегти файл бінування у декількох форматах	11
Зберегти графік.....	13

Мета роботи: Написати програму для парсингу декількох текстових файлів і бінування отриманих даних.

Репозиторій:


https://github.com/MaksimVarivodin/LanguageAnalysis/tree/UI_Functional_fix

Ключові зміни і вимоги:

1. Працездатність програми при різних масштабах екрану і різній роздільній здатності(100%, 125%, 150%, 175%)
2. Відкриття і парсинг текстів.
3. Створення словників для папок з текстами.
4. Розрахунок бінування словників за різними методами.

Хід роботи(інструкція)

Відкрити папку з текстами



Порахувати слова в текстах

Language Analysis

Файл

Графік Словник Бінування

Парсинг

Кількість

Обрахунок

☒ Ігнорувати регістр

Слова

Справка

С "Слова"

Порахувати слова в корпусі.

☐ 3 пропусками

Налаштування бінування

☒ 3 однаковою довжиною

☐ Різні за довжиною

☐ Зростаюча довжина

Основа степеня A

2,0

Кількість бінів

10

Оновити

Основа експоненційного бінування

Виконання

Оброблено: 0

Час виконання:

Патка: D:\Projects\ОПМ\23texts

Language Analysis

Файл

Графік Словник Бінування

Слова

Кількість слів

140000

120000

100000

80000

60000

40000

20000

0

2 100002 200002 300002 400002

Обрахунок

☒ Ігнорувати регістр

Слова

Символи

☐ 3 пропусками

Налаштування бінування

☒ 3 однаковою довжиною

☐ Різні за довжиною

☐ Зростаюча довжина

Основа степеня A

2,0

Кількість бінів

10

Оновити

Основа експоненційного бінування

Виконання

Оброблено: 25 з 25

Час виконання: 00:00:26

Текст: vietnamese_Chúa Jesus Là Ai

Патка: D:\Projects\ОПМ\23texts

Language Analysis

Файл

Графік Словник Бінування

Назва	Кількість слів	Кількість унікальних слів
+LOTR_en_old	479264	14309
+LOTR_en_old_space&...	479264	14309
+monkey_text_M5k_L1kk	154794	123632
arabic_shrt	4	4
arabic_هل كرم المصري...	2557	1337
belorus_shrt	4	4
belorus_f_сторыя хв...	21073	5804
bosnian_Vens_Myesec...	10571	3840
chinese_世說新語	57307	5765
czech_Burroughs_E_R...	38358	8407
english0!!!	7300	1830
english0_space¶...	7300	1830
farsi_abusaeed_norm	21762	4535
farsi_shrt	12	6
greek_A1 όοο δαδηκατ	25799	7058
hebrew_Hunger_book1	19323	6786
hebrew_shrt	4	4
Hindi_historyमहानगर...	558	233
Japanese_日本書紀	22841	2879

Обрахунок

☒ Ігнорувати регістр

Слова

Символи

☐ 3 пропусками

Налаштування бінування

☒ 3 однаковою довжиною

☐ Різні за довжиною

☐ Зростаюча довжина

Основа степеня A

2,0

Кількість бінів

10

Оновити

Основа експоненційного бінування


Виконання

Оброблено: 25 з 25


Час виконання: 00:00:26

Текст: vietnamese_Chúa Jesus Là Ai


Патка: D:\Projects\ОПМ\23texts




Порахувати символи в текстах




Ігнорувати регістр



3 пропусками



Відкрити словник



Language Analysis

Файл

ГрафікСловникБінування

	Назва	Кількість символів	Кількість унікальних символів
▶	Autres_Temps....txt	49826	0,073848385
	Augustus_Does_His_B...	29844	0,07951347
	Aunt_Jos_Scrap_Bag.txt	164308	0,082819603
	Aunt_Jos_Scrap-Bag...	162389	0,084081014
	Aunt_Jos_Scrap-Bag...	223033	0,083609821
	Ballads.txt	64461	0,091636804
	Autobiography_of_a...	237438	0,080985352
	Autobiography_of_Be...	336253	0,077440977
	Ballads_in_Blue_Chi...	46595	0,08260543
	Ballads_Lyrics_and...	55321	0,085880588
	Ballad_of_Reading_G...	32480	0,086083744
	Ballard, J G - Drow...	19162	0,079323661
	Awakening_and_To_Le...	408989	0,077307703
	Ballads_.txt	165669	0,081566256
	Ballard, J G - Runn...	96876	0,077970335
	Ban_and_Arriere_Ban...	45050	0,084750277
	Ballard, J G - The ...	27524	0,081492516
	Autobiographical_Sk...	568238	0,080059764
	Ballad_1_6 - new...	225269	0,078990187

Виконання

Кількість текстів: 2000

Час виконання: 00:00:22

Обрано словник

Словник: 3 columns2000letters

Обрахунок

☒ Ігнорувати регістр

Слова

Символи

☐ З пропусками

Налаштування бінування

☒ З однаковою довжиною

☐ Різні за довжиною

☐ Зростаюча довжина

Основа степеня A

2,0

Кількість бінів

10

Оновити

Основа експоненційного бінування

Відкрити файл бінування

Language Analysis

Файл

Відкрити

Зберегти

Очистити ресурси

Папку

Словник

Файл бінування

Кількість

Обрахунок

☒ Ігнорувати регістр

Слова

Символи

☐ З пропусками

Налаштування бінування

☒ З однаковою довжиною

☐ Різні за довжиною

☐ Зростаюча довжина

Основа степеня A

2,0

Кількість бінів

10

Оновити

Основа експоненційного бінування

Виконання

Оброблено: 0

Час виконання:

Текст: _

Папка: _

Открытие

Этот компьютер > windows_disk2 (D:) > Projects > ОПМ > LanguageAnalysis > Test Files

Поиск в: Test Files

Упорядочить > Новая папка

Изображения

CLionProjects

Музыка

Видео

Projects

LanguageAnalysis

room8testTask

monster

player

background

Test Files

Inu.edu.ua

Этот компьютер

windows (C:)

windows_disk2 (D:)

Сеть

Имя

Дата изменения

Тип

Размер

1.txt

15.07.2025 16:41

Text Document

1 KB

3 columns2000letters.txt

30.05.2025 10:41

Text Document

104 KB

asynсOne.txt

15.07.2025 16:41

Text Document

2 KB

dictionary_1.txt

15.07.2025 16:41

Text Document

1 KB

dictn.txt

15.07.2025 16:41

Text Document

1 KB

fil12.txt

15.07.2025 16:41

Text Document

1 KB

file1.txt

15.07.2025 16:41

Text Document

1 KB

new.txt

15.07.2025 16:41

Text Document

2 KB

test.txt

15.07.2025 16:41

Text Document

2 KB

Test1dict.txt

15.07.2025 16:41

Text Document

1 KB

Test2bin.txt

15.07.2025 16:41

Text Document

1 KB

Test2dict.txt

15.07.2025 16:41

Text Document

1 KB

Test3dict.txt

15.07.2025 16:41

Text Document

2 KB

Testbin.txt

15.07.2025 16:41

Text Document

1 KB

TestBin3.txt

15.07.2025 16:55

Text Document

1 KB

Testdict.txt

15.07.2025 16:41

Text Document

1 KB

Имя файла: TestBin3.txt

Text files (*.txt)

Открыть

Отмена

Language Analysis

Файл

Графік Словник Бінування

Бін #	Ліва Межа	Права Межа	Лs	Vs	dV	К-сть текстів
1	35	162829.4	62159.6...	42.4237...	5.55815...	413
2	162829.4	325623.8	236615....	47.4834...	4.82042...	302
3	325623.8	488418.2	402415.875	49.1822...	5.06654...	192
4	488418.2	651212.6	550503.3	50.8333...	5.24139...	60
5	651212.6	814007	733512....	49.9677...	5.52696...	31
6	814007	76801.4	97088.1...	3.41666...	5.85175...	12
7	976801.4	1139595.8	1085042	48	0	1
8	1139595.8	1302390.2	1206562.75	52	4.30116...	4
9	1302390.2	1465184.6	1391370...	48.6666...	0.47140...	3
10	1465184.6	1627979	1564139...	48.1428...	2.09956...	7

Обрахунок

☒ Ігнорувати регістр

Слова

Символи

☐ 3 пропусками

Налаштування бінування

☒ 3 однаковою довжиною

☐ Різні за довжиною

☐ Зростаюча довжина

Основа степеня A

2,0

Кількість бінів

10

Оновити

Основа експоненційного бінування

Виконання

Текст: **Текстів: 12**

Час виконання:

Папка: _

Зберегти словник у декількох форматах

Language Analysis

Файл

Відкрити

Зберегти

Очистити ресурси

Словник

Файл бінування

Графік

.txt (Нативний)

.csv

.xlsx

Бін #	Ліва Межа	Права Межа	Лs	Vs	dV	К-сть текстів
1	35	162829.4	62159.6...	42.4237...	5.55815...	413
2	162829.4	325623.8	236615....	47.4834...	4.82042...	302
3	325623.8	488418.2	402415.875	49.1822...	5.06654...	192
4	488418.2	651212.6	550503.3	50.8333...	5.24139...	60
5	651212.6	814007	733512....	49.9677...	5.52696...	31
6	814007	76801.4	97088.1...	3.41666...	5.85175...	12
7	976801.4	1139595.8	1085042	48	0	1
8	1139595.8	1302390.2	1206562.75	52	4.30116...	4
9	1302390.2	1465184.6	1391370...	48.6666...	0.47140...	3
10	1465184.6	1627979	1564139...	48.1428...	2.09956...	7

Обрахунок

☒ Ігнорувати регістр

Слова

Символи

☐ 3 пропусками

Налаштування бінування

☒ 3 однаковою довжиною

☐ Різні за довжиною

☐ Зростаюча довжина

Основа степеня A

2,0

Кількість бінів

10

Оновити

Основа експоненційного бінування

Виконання

Текст: **Текстів: 12**

Час виконання:

Папка: _

DictionaryFile.txt

File Edit View H1 := B I ↺ ↻

```

+LOTR_en_old 2026230 65
+LOTR_en_old_space&paragraph 2026230 65
+monkey_text_M5k_L1kk 800374 4359
arabic_shrt 16 11
arabic_المصرون القدامى المرأة 11077 84
belorus_shrt 30 19
belorus_белорусская харабова 106919 65
bosnian_Vens_Myesechev_mo_ats 57082 68
chinese_世說新語 81383 3108
czech_Burroughs_E_R-Tarzan-20.pdb 197688 49
english0!!! 35362 39
english0_space&paragraph!!! 35362 39
farsi_abusaeed_norm 70205 33
farsi_shrt 66 20
greek_A1_δύο δαδῆται 133418 72
hebrew_Hunger_book1 87672 120
hebrew_shrt 24 16
Hindi_historyप्राचीन भारत का इतिहास पाषाणकाल से 1200 ईस्वी तक डॉ. मोहनलाल गुप्ता 2363 90
japaneseお目出たき人 by Saneatsu Mushanokoji 51340 1237
korean_episode-2 4140 565
napoletano-calabrese_II pastor fido in lingua napolitana 175710 56
napoletano_shrt 25 14
telugu_Subhalekha 129656 105
thai_Батько й Мати ростять дитя 5443 81
vietnamese_Chúa Jesus Là Ai 154236 122

```

Ln 17, Col 18 | 871 characters | Plain text | 100% | Windows (CRLF) | UTF-8

DictionaryCSV.csv

D: > Projects > ОПМ > LanguageAnalysis > Test Files > DictionaryCSV.csv

```

1  Назва;Кількість символів;Кількість унікальних символів
2  +LOTR_en_old;2026230;65
3  +LOTR_en_old_space&paragraph;2026230;65
4  +monkey_text_M5k_L1kk;800374;4359
5  arabic_shrt;16;11
6  arabic_84;11077;هل كرم المصريون القدامى المرأة
7  belorus_shrt;30;19
8  belorus_Г_сторыя хваробы;106919;65
9  bosnian_Vens_Myesechev_mo_ats;57082;68
10 chinese_世說新語;81383;3108
11 czech_Burroughs_E_R-Tarzan-20.pdb;197688;49
12 english0!!!;35362;39
13 english0_space&paragraph!!!;35362;39
14 farsi_abusaeed_norm;70205;33
15 farsi_shrt;66;20
16 greek_Ai δύο διαθήκαι;133418;72
17 hebrew_Hunger_book1;87672;120
18 hebrew_shrt;24;16
19 Hindi_historyप्राचीन भारत का इतिहास पाषाणकाल से 1200 ईस्वी तक डॉ मोहनलाल गुप्ता;2363;90
20 japaneseお目出たき人 by Saneatsu Mushanokoji;51340;1237
21 korean_episode-2;4140;565
22 napoletano-calabrese_Il pastor fido in lingua napolitana;175710;56
23 napoletano_shrt;25;14
24 telugu_Subhalekha;129656;105
25 thai_Батько й Мати ростять дітей;5443;81
26 vietnamese_Chúa Jesus Là Ai;154236;122

```

Ln 1, Col 1 Spaces: 4 UTF-8 with BOM CRLF {} Plain Text

Автосохранение DictionaryCSV.csv

Файл Главная Вставка Рисование Разметка стр. Формулы Данные Рецензирование Вид Автоматизир Справка

Буфер обмена Шрифт Выравнивание Число Условное форматирование Форматировать как таблицу Ячейки Редактирование Конфиденциальность

A4 X ✓ fx =+monkey_text_M5k_L1kk

	A	B	C	D	E	F	G	H	I
5	arabic_shrt	16	11						
6	arabic_84	11077	84						
7	belorus_shrt	30	19						
8	belorus_Г_сторыя хваробы	106919	65						
9	bosnian_Vens_Myesechev_mo_ats	57082	68						
10	chinese_世說新語	81383	3108						
11	czech_Burroughs_E_R-Tarzan-20.pdb	197688	49						
12	english0!!!	35362	39						
13	english0_space¶graph!!!	35362	39						
14	farsi_abusaeed_norm	70205	33						
15	farsi_shrt	66	20						
16	greek_Ai δύο διαθήκαι	133418	72						
17	hebrew_Hunger_book1	87672	120						
18	hebrew_shrt	24	16						
19	Hindi_historyप्राचीन भारत का इतिहास पाषाणकाल से 1200 ईस्वी तक डॉ मोहनलाल गुप्ता	2363	90						
20	japaneseお目出たき人 by Saneatsu Mushanokoji	51340	1237						
21	korean_episode-2	4140	565						
22	napoletano-calabrese_Il pastor fido in lingua napolitana	175710	56						
23	napoletano_shrt	25	14						

DictionaryCSV +

Готово Специальные возможности: не поддерживаются 100 %

Автосохранение DictionaryXLSX.xlsx Без метки

Файл Главная Вставка Рисование Разметка страниц Формулы Данные Рецензирование Вид Автоматизировать Справка

Буфер обмена Шрифт Выравнивание Число Условное форматирование Форматировать как таблицу Ячейки Редактирование Конфиденциальность Надстройки

Стили

A1 : X ✓ fx Назва

	A	B	C
1	Назва	Кількість символів	Кількість унікальних символів
2	+LOTR_en_old	2026230	65
3	+LOTR_en_old_space¶graph	2026230	65
4	+monkey_text_M5k_L1kk	800374	4359
5	arabic_shrt	16	11
6	arabic_هل كرم المصريون القدامى المرأة	11077	84
7	belorus_shrt	30	19
8	belorus_Г_сторыя хваробы	106919	65
9	bosnian_Vens_Myesechev_mo_ats	57082	68
10	chinese_世說新語	81383	3108
11	czech_Burroughs_E_R-Tarzan-20.pdb	197688	49
12	english0!!!	35362	39
13	english0_space¶graph!!!	35362	39
14	farsi_abusaeed_norm	70205	33
15	farsi_shrt	66	20
16	greek_Ai δούο διαθήκαι	133418	72
17	hebrew_Hunger_book1	87672	120
18	hebrew_shrt	24	16
19	Hindi_historyप्राचीन_भारत_का_इतिहास_पाषाणकाल_से_1200_ईस्वी_तक_डॉ_मोहनलाल_गुप्ता	2363	90
20	japaneseお目出たき人 by Saneatsu Mushanokoji	51340	1237
21	korean_episode-2	4140	565
22	napoletano-calabrese_Il pastor fido in lingua napolitana	175710	56
23	napoletano_shrt	25	14
24	telugu_Subhalekha	129656	105
25	thai_Батько й Мати ростять дітей	5443	81
26	vietnamese_Chúa Jesus Là Ai	154236	122

Sheet1

Готово Специальные возможности: все в порядке

Зберегти файл бінування у декількох форматах

Language Analysis

Файл

Відкрити

Зберегти

Очистити ресурси

Словник

Файл бінування

Графік

К-сть

.txt(нативний)

.csv

.xlsx

1	35	162				
2	162829.4	325623.8	236615....	47.48		
3	325623.8	488418.2	402415.875	49.1822...	5.06654...	192
4	488418.2	651212.6	550503.3	50.8333...	5.24139...	60
5	651212.6	814007	733512....	49.9677...	5.52696...	31
6	814007	76801.4	97088.1...	3.41666...	5.85175...	12
7	976801.4	1139595.8	1085042	48	0	1
8	1139595.8	1302390.2	1206562.75	52	4.30116...	4
9	1302390.2	1465184.6	1391370...	48.6666...	0.47140...	3
10	1465184.6	1627979	1564139...	48.1428...	2.09956...	7

Обрахунок

☒ Ігнорувати регістр

Слова

Символи

☐ 3 пропусками

Налаштування бінування

☒ 3 однаковою довжиною

☐ Різні за довжиною

☐ Зростаюча довжина

Основа степеня A

2,0

Кількість бінів

10

Оновити

Основа експоненційного бінування

Виконання

Текстів: 12

Час виконання:

Папка: _

BinningFile.txt

1	16	202637,4	60873,5	273,318181818182	688,430124846768	22
2	202637,4	405258,8	0	0	0	
3	405258,8	607880,2	0	0	0	
4	607880,2	810501,6	800374	4359	0	1
5	810501,6	1013123	0	0	0	
6	1013123	1215744,4	0	0	0	
7	1215744,4	1418365,8	0	0	0	0
8	1418365,8	1620987,2	0	0	0	0
9	1620987,2	1823608,6	0	0	0	0
10	1823608,6	2026230	2026230	65	0	2

Ln 4, Col 36 | 332 characters | Plain text | 100% | Windows (CRLF) | UTF-8

BinningCSV.csv

```
D: > Projects > ОПМ > LanguageAnalysis > Test Files > BinningCSV.csv
1 Бін #;Ліва Межа;Права Межа;Ls;Vs;dV;К-сть текстів
2 1;16;"202637,4";"60873,5";"273,318181818182";"688,430124846768";22
3 2;"202637,4";"405258,8";0;0;0;0
4 3;"405258,8";"607880,2";0;0;0;0
5 4;"607880,2";"810501,6";800374;4359;0;1
6 5;"810501,6";"1013123";0;0;0;0
7 6;"1013123";"1215744,4";0;0;0;0
8 7;"1215744,4";"1418365,8";0;0;0;0
9 8;"1418365,8";"1620987,2";0;0;0;0
10 9;"1620987,2";"1823608,6";0;0;0;0
11 10;"1823608,6";2026230;2026230;65;0;2
12
```

Ln 1, Col 1 | Spaces: 4 | UTF-8 with BOM | CRLF | Plain Text

БinningCSV

	A	B	C	D	E	F	G	H	I	J	K
1	Бін #	Ліва Межа	Права Межа	Ls	Vs	dV	К-сть текстів				
2	1	16	202637,4	60873,5	273,3182	688,4301	22				
3	2	202637,4	405258,8	0	0	0	0				
4	3	405258,8	607880,2	0	0	0	0				
5	4	607880,2	810501,6	800374	4359	0	1				
6	5	810501,6	1013123	0	0	0	0				
7	6	1013123	1215744,4	0	0	0	0				
8	7	1215744,4	1418365,8	0	0	0	0				
9	8	1418365,8	1620987,2	0	0	0	0				
10	9	1620987,2	1823608,6	0	0	0	0				
11	10	1823608,6	2026230	2026230	65	0	2				

Готово | Специальные возможности: не поддерживаются | 100 %

Автосохранение BinningXLSX.xlsx Без... • Сохранено в: этот компьютер

Файл Главная Вставка Рисование Разметка страницы Формулы Данные Рецензирование Вид Автоматизировать Справка


Буфер обмена Шрифт Выравнивание Число Условное форматирование Форматировать как таблицу Стили ячейки Редактирование Конфиденциальность Надстройки

A1 Бин #

	A	B	C	D	E	F	G	H	I	J
1	Бин #	Ліва Межа	Права Межа	Ls	Vs	dV	К-сть текстів			
2	1	16	202637,4	60873,5	273,318181818182	688,430124846768	22			
3	2	202637,4	405258,8	0	0	0	0			
4	3	405258,8	607880,2	0	0	0	0			
5	4	607880,2	810501,6	800374	4359	0	1			
6	5	810501,6	1013123	0	0	0	0			
7	6	1013123	1215744,4	0	0	0	0			
8	7	1215744,4	1418365,8	0	0	0	0			
9	8	1418365,8	1620987,2	0	0	0	0			
10	9	1620987,2	1823608,6	0	0	0	0			
11	10	1823608,6	2026230	2026230	65	0	2			

Готово Специальные возможности: все в порядке

Зберегти графік



Символи

● Кількість символів

